

대학원 트랙 아이디어 지도

첫 프레임 한 장과 16스텝짜리 로봇 관절 명령만으로 미래 영상을 만들어야 하는 과제. 8개 팀이 어떤 백본 위에서, 액션을 어떤 경로로 밀어 넣고, 무엇을 손실로 삼았는지를 그림으로 정리했다.

대상 grad/team1 - team10 제출 팀 8팀 (team6 제출물 없음) 근거 제출 README · config · 코드 · 검사보고서
정리일 2026-09-07

요약

먼저 알아야 할 세 가지

01

백본 선택이 곧 전략이었다

대회가 준 DynamiCrafter 1.4B로 버틴 3팀은 예산을 **학습 스텝**에 쏟았고, 외부 대형 모델(Wan·Cosmos·SVD)로 갈아탄 5팀은 백본을 열린 채 **LoRA·어댑터**로만 액션을 가르쳤다.

02

모두가 “액션이 되었는지” 검사했다

지각손실(team7) · 잠재 IDM(team4) · 액션 판독기(team5) · 대조 힌지(team2) · 모션 정합 손실(team10). 이름은 달라도 전부 “**생성 결과에서 액션이 복원돼야 한다**”는 같은 명제의 구현이다.

03

끝에서는 8팀 중 6팀이 같은 처방

움직이지 않아야 할 픽셀을 **첫 프레임으로 되돌리는** 후처리. 채점의 60%가 프레임 특징 거리라 배경 흔들림이 곧 감점이기 때문이다. team10은 아예 43편을 정지영상으로 바꿨다.

한눈에 보는 8팀

팀	백본	액션 주입	핵심 아이디어	후처리	PUBLIC
team7	DynamiCrafter 1.4B	프레임 AdaGN	채점과 같은 특징공간 (DINOv2-R3D)을 지각손실로 사용	없음	0.157330
team5	Wan2.1-VACE-14B · TI2V-5B	골격 렌더 (구조 조건)	클릭 캘리브레이션 + 잠재 액션 판독 손실 + 구간 스택킹	f0 교체·배경 오프셋	0.165847
team2	Ctrl-World (SVD)	cross-attn + 액션 헤드	액션 대조 힌지로 “조건 무시”를 직접 억제	frame-0 하드마스크	0.165933
team10	DynamiCrafter 512	블록별 adaLN-Zero	모션 정합 손실 + 액션 임계로 정지 샘플 스위칭	정지영상 대체 43편	0.172537
team8	Cosmos-Predict2.5-2B	사전학습 + xattn 어댑터	warped noise — 광류로 노이즈를 미리 뒤틀어 시간 일관성 확보	static_anchor_v1	0.196397
team1	Wan2.2-TI2V-5B (동결)	AdaLN 84D + cross-attn	URDF 순기구학으로 관절각을 3D 팔 자세로 바꿔 투입	없음	—
team3	DynamiCrafter 계열	12D + depth 채널 + 텍스트	예측기 초안 → 확산 정련의 2단 구조, VLM 캡션 조건	잔차 합성·모션 마스크	—
team4	Cosmos-Predict2.5-2B	사전학습 + 6D embedder	잠재 역동역학(IDM) 보조 + 체크포인트 수프	배경 앵커 (45° 초과)	—

점수는 **낮을수록 좋다**. “—”는 제출 문서에 리더보드 점수가 적히지 않은 팀이다. Private 점수는 team5(0.203079)만 기재돼 있어 팀 간 최종 성능 비교는 이 표로 할 수 없다 — **설계를 비교하기 위한 표**다.

왜 다들 “정지”에 집착했나

팀들의 선택을 이해하려면 채점식부터 봐야 한다. 점수는 **낮을수록 좋은 거리값**이고, 세 성분의 가중평균이다. 그중 **Action 성분만 참가자가 스스로 계산할 수 있다**.




그림 1. 채점 경로. 여기서 두 가지가 따라 나온다 — ① DINO·Video가 합쳐서 **0.6**이고 둘 다 프레임 특징의 코사인 거리라, 배경이 미세하게 흔들리면 그대로 감점이다(→ 모든 팀의 정지 처방). ② Action 성분은 킷이 eval 정답과의 MAE를 CSV에 적어 주므로 혼자서 채점해 볼 수 있다(→ 여러 팀의 규정 쟁점).

02 — 첫 갈림길

어느 백본을 믿을 것인가

8팀의 차이는 대부분 이 하나의 선택에서 갈라진다. 대회가 준 **DynamiCrafter 1.4B**를 깊게 팔 것인가, 아니면 훨씬 큰 외부 사전학습 영상모델로 갈아탈 것인가. 전자는 4일 예산을 학습 스텝에 몰아넣을 수 있고, 후자는 사전학습된 영상 품질을 그대로 가져오는 대신 액션은 어댑터·LoRA로만 가르쳐야 한다.




그림 2. Cosmos 계열 두 팀만 “이미 액션 조건이 붙은” 모델에서 출발했다. 나머지 여섯 팀은 액션 입력 경로를 직접 만 들어 붙여야 했고, 그 설계가 팀별 최대 차별점이다(그림 3).

03 — 두 번째 갈림길

액션 6차원을 영상으로 흘러보내는 네 가지 통로

입력은 (16, 6) 관절 명령 하나뿐이다. 이 작은 텐서가 UNet/DiT 안쪽 어디에 닿게 하느냐가 네 갈래로 갈랐다. 여러 통로를 함께 쓴 팀도 있다.



그림 3. ①은 zero-init 덕에 “붙여도 처음엔 결과가 안 바뀌는” 안전한 출발점을 주므로 대회 백본을 고친 팀들이 택했고, ②는 대형 사전학습 모델을 열린 채 붙이기 좋아 외부 백본 팀이 택했다. ③은 팔의 위치를 픽셀 공간에서 지정하는 유일한 방식이라 캘리브레이션 작업이 따라붙는다.


여덟 개의 답안

백본 계열 순서로 본다. 각 팀은 한 줄 아이디어 → 세 줄 요약 → 파이프라인 그림 → 상세 제원 순서로 같은 틀을 쓴다. 그림은 위가 학습, 아래가 추론이다.

대회 백본을 3파일 · 72줄만 고쳐서, 액션 이 UNet의 모든 블록 경계에서 말하게 만들었다.

무엇을	UNet 25개 블록마다 액션 임베딩에서 scale/shift를 만들어 $h = h \cdot (1+\gamma) + \beta$ 를 적용하는 adaLN-Zero 변조. 마지막 linear를 0으로 초기화해 붙인 직후의 forward는 원본과 완전히 동일하다.
왜 통했나	“지시가 정지면 영상도 정지해야 한다”를 학습·추론 양쪽에서 이중으로 강제했다. 학습에서는 모션 정합 손실 2종(액션 travel 프로파일과의 상관 / GT 프레임차와의 L1), 추론에서는 액션 travel 이 임계 τ 미만인 샘플을 정지영상으로 대체(216 중 43편).
남은 문제	2026-08-13 클라우드 인스턴스 회수로 학습 로그가 유실 됐고, 모션 손실 v2 코드는 사양 기록에 따라 재작성한 것이다. 제출 체크포인트로 CSV를 재현하는 경로에는 영향이 없다.

학습



추론



그림 4. team10 — 216편 중 43편은 모델이 만든 영상을 아예 쓰지 않는다.

백본	DynamiCrafter 512 (challenge_kit 구현) · 액션 절대각 6차원
학습	stage1 66h → merge → stage2 lr 5e-6, batch 2×accum 4, 최대 28,000 step / 19h · 단일 RTX PRO 6000
보조 손실	모션 정합 v1 0.05 (액션 travel 상관) · v2 0.2 (GT 프레임차 L1, scale-aware)
추론	DDIM 50 step, η 1.0, guidance_rescale 0.7, uniform_trailing, batch 1, seed 0 — 약 56분
변경 규모	원본 kit 대비 3개 파일 +72 / -2 라인 · adaLN 모듈 약 55M

채점이 DINOv2와 R3D로 쟁다면, 학습 손실도 그 특징 공간에서 재면 된다.

무엇을

조건 주입은 가장 단순하다 — 액션 12차원(절대 6 + 델타 6)을 **프레임 단위 AdaGN 경로 하나로**만. 대신 1단계에 80,000 step을 쏟고, 2단계 5,000 step에서 **지각손실**을 건다. 감독 특징이 `DINOv2 dense 패치토큰 + r3d_18` — **채점의 두 성분과 같은 계열**이다.

왜 통했나

지표를 향해 좌표를 직접 튜닝했다. README에 CLS 토큰 대신 dense 패치를 쓴 이유, `lam·t_gate·n_frames`의 각 대안이 점수를 얼마나 악화시키는지가 표로 다 적혀 있다. 추론도 **DDIM 17 step**으로 끊어 점수 -0.004를 내주고 시간을 1/3로 줄였다.

남은 문제

체크포인트 10개 중 하나를 고르는 데 쓴 **자체 채점기 `local_scorer.py`**가 제출물에 없다. “왜 80k를 골랐는가”를 확인할 수 없어 검사보고서가 최종대 사안으로 지목했다.

학습



추론




그림 5. team7 — 후처리 없이 모델 출력을 그대로 낸 두 팀 중 하나. 대신 체크포인트 선택 도구가 빠져 있다.

백본	DynamiCrafter_512 1.4B (공식 backbone.ckpt, Apache-2.0)
1단계	80,000 step · lr 1e-5 · accum 2 · frame stride 24 · action_dropout 0.1
2단계	5,000 step · lr 5e-6 · 8bit AdamW · 지각손실 lam 0.05 / t_gate 0.6 / n_frames 2 · A6000 약 6.5h
추론	DDIM 17 step · action CFG 2.0 · EMA · 재현 35분 / 26.7 GiB
데이터	체스판 계열 6개 데이터셋 블록리스트 제외

먼저 한 번에 예측하고, 확산은 그 예측 위를 다듬는 데만 쓴다.

무엇을 유일하게 모델을 둘로 나눴다. 1-pass 잠재 예측기 P 가 액션에 맞는 latent 궤적 초안을 한 번에 뽑고, v-확산 D 가 strength 0.65 img2img로 그 위를 다듬는다.


왜 통했나 확산에게 “무에서 만들라”가 아니라 “이 초안을 고쳐라”를 시키므로 25 step만으로도 궤적이 무너지지 않는다. 조건도 가장 다층적이다 — 액션 12D + depth 채널 + Qwen2.5-VL-7B 캡션에서 뽑은 태스크 토큰 + 액션 통계를 자연어로 옮긴 구절(“Motion: slight quick, gripper closes.”).

남은 문제 태스크 토큰을 만들 때 eval 캡션 216개까지 통계 모집단에 포함했다(transductive). 검사보고서는 이를 Violation으로 지적했고, 학습 4개 실행의 world_size 합산도 예산 초과 정황으로 봤다.

학습



추론



쟁점 — eval 캡션 216개까지 포함해 IDF 통계를 낸 뒤 태스크 토큰을 분류(transductive)

그림 6. team3 — 확산 앞단에 결정론적 예측기를 둔 “초안 → 정련” 구조는 이 팀뿐이다.

백본 DynamiCrafter 계열 LatentVisualDiffusion · action_dims 12 · image_proj 학습

구성 모델 예측기 P (predictor.ckpt) + v-확산 D (diffusion.ckpt) 2개

보조 조건 VLM 캡션 · 태스크 토큰 · 액션→자연어 모션 구절 · depth 채널

추론 strength 0.65 · DDIM 25 · η 0.5 · CFG 1.5 · negative “static” · residual blend 1.20

합성 제어 per-frame 모션 마스크 · 저역 성분 이식(lowpass_concat) · 공간·시간 언샤프

관절 각도 6개를 그대로 주지 말고, 순기구학으로 3D 공간의 팔 자세로 바꿔서 주자.

무엇을 SO-ARM100 공개 URDF에서 관절 위치·회전축·가동범위를 뽑아 상수로 박고, **순기구학 $fk()$ 로 관절각을 3D 팔 자세로 변환**해 ΔFK 와 집게 특징을 조건으로 넣는다. AdaLN 84차원 + cross-attention 57열이 전부 이 기하 특징에서 나온다.

왜 통했나 모델이 “관절각 → 화면상 팔 위치”라는 어려운 매핑을 처음부터 배울 필요가 없다. 덕분에 백본(Wan2.2-TI2V-5B)은 통째로 얼리고 학습 대상이 **71.44M**뿐이며, 예산도 가장 가볍다 — 학습 36h(한도의 37.5%), 추론 16.8분(한도의 28%).

남은 문제 URDF는 **주최가 제공하지 않은 외부 자료**다. 실행 중 다운로드는 없고 출처·해시도 명기했지만, “제공 데이터만 사용” 규정이 데이터셋만 제한하는지 모든 외부 자료를 제한하는지에 판정이 걸린다.




그림 7. team1 — 로봇 하드웨어 사전지식(URDF)이 장면 선별부터 추론까지 전 구간의 축이다. 빼면 동작하지 않는다.

백본	Wan2.2-TI2V-5B (동결) + FastWan2.2-TI2V-5B VAE · 둘 다 Apache-2.0
학습	단일 런 0 → 30,000 step · Flow Matching 단독 · 학습 VRAM 12.0 GB · 36.0h (RTX 4090 실측)
조건	URDF 기반 ΔFK · 집게 힌지/축 · AdaLN 84D + cross-attn 57열
추론	216 샘플 16.8분 · VRAM 20.18 GB · 후처리 없음 · 샘플 간 상호작용 없음
확인 필요	외부 URDF 사용 허용 여부 · T_TIP 적합 스크립트 미제출 · 로그상 실제 38,121 step

팔이 어디에 있어야 하는지를 그려서 보여준 다 – 사람이 클릭해 맞춘 골격을 조건 영상으로.

무엇을

액션을 숫자가 아니라 **픽셀로 넣는다**. 사람이 프레임 위 관절을 클릭한 주석만으로 기구 파라미터와 카메라를 동시에 적합한 뒤, 액션 시퀀스를 **골격 렌더**로 바꿔 조건 영상으로 준다. Wan2.1-VACE-14B가 원래 이런 구조 조건을 받는 모델이라 궁합이 맞는다.


왜 통했나

여기에 **잠재 액션 판독기**(L_{act})가 생성 latent에서 액션을 되읽어 그 오차를 손실에 더한다. 추론은 **구간별 스택킹** – sid 0–64는 VACE 시드0, 65–153은 VACE 시드1, 154–215는 별도 TI2V-5B LoRA.

남은 문제

킷이 뿜는 Action 점수를 보고 저장 해상도와 후보를 정한 흔적이 스크립트 주석에 그대로 남아 있다 ("320x512면 action 0.41→0.69"). 검사보고서의 최종대 지적이며, 팀 스스로 완전 재현 불가를 기재했다.

전처리 · 학습



추론 – 구간별 스택킹



그림 8. team5 – 조건을 픽셀 공간에 그려 넣는 접근과, 샘플 구간마다 생성원을 바꾸는 스택킹이 함께 들어갔다.

백본	Wan2.1-VACE-14B (주력) + Wan2.2-TI2V-5B (sid 154–215) · 둘 다 Apache-2.0
전처리	클릭 주석 → 기구·카메라 동시 적합 → 골격 렌더 · 학습 페어 4,632쌍
학습	VACE LoRA r32 12k + 4k 연장 ($\approx 21.7h$) · dtn FiLM LoRA 750 step · 합계 약 1.5일
추론	구간별 모델·시드 스택 · 합계 약 50분 (0–153 재생성 리허설 35분 57초)
가중치	<code>lora14b_7p_16k_final.safetensors</code> · <code>latent_readout.pt</code> · <code>dtnM2/</code>

생성한 영상에서 액션이 되읽혀야 한다 – 역동역학 모델을 심판으로 세운다.

무엇을	출발점(Cosmos-Predict2.5-2B)이 이미 action-conditioned이라 “액션을 어떻게 넣을까”는 물려받고, “ 액션대로 움직였는지 어떻게 검사할까 ”에 예산을 썼다. Stage 1 LoRA 학습 → 그 latent 위에서 잠재 IDM (연속 latent에서 액션을 역추정하는 모델)을 25k step 별도 학습 → Stage 2에서 IDM을 보조 신호로 붙여 다시 25k step.
왜 통했나	마무리는 체크포인트 수프 — Stage 2 마지막 네 지점을 평균해 단일 지점 선택의 분산을 줄였다. 후처리는 액션 한 축만 본다: shoulder-lift 평균이 45°를 넘는 샘플에만 배경 앵커.
남은 문제	제출 영상을 만든 스크립트(own_bon.py)가 패키지에 없고, IDM·soup 단계의 stdout 로그도 미보존이다. 다만 Private 재현 오차가 0.122% 로 나와 재현 성공 판정을 받았다.




그림 9. team4 — IDM을 “액션 재현도 심판”으로 세운 것이 핵심이고, 수프로 선택 분산을 줄였다.

백본	NVIDIA Cosmos-Predict2.5-2B action-cond (고정 commit) · NVIDIA Open Model License
학습	LoRA r32 (28 DiT block self/cross-attn + MLP) + 6D action embedder · 113.4M · seed 20260807 / sampler 1234
보조 신호	train latent 전용 잠재 IDM (batch 64 · lr 3e-4 · EMA 0.999 · 25,000 step)
추론	Flow UniPC 30 step · shift 5 · seed 7 · auto-guidance 0.6 · LoRA scale 1
재현	Private 재현 오차 0.122% — 세 성분이 고르게 흩어져 무작위 재생성 차이로 판단

노이즈부터 움직이게 한다 — 광류로 미리 뒀 튼 노이즈를 주어 시간 일관성을 확보한다.

무엇을	같은 Cosmos 2B에서 출발하지만 접근이 반대쪽이다. team4가 출력을 검사한다면, 이 팀은 입력 노이즈를 손본다 . 프레임 간 광류로 노이즈를 미리 warp해 두면 프레임마다 독립적인 가우시안 노이즈가 만드는 깜빡임이 줄어든다.
왜 통했나	flow cache 생성 → 노이즈 사전계산 → warped 10k step → 액션 cross-attn 어댑터 10k step으로 이어지는 8팀 중 가장 긴 학습 체인 (누적 120,000 update $\approx$ 80시간)을 돌렸다. 다만 최종 제출본은 어댑터의 추론 가중치를 0.0 으로 두었다 — 학습해 놓고 껴다.
남은 문제	39라운드 제출 이력과 라운드별 provenance·MANIFEST 해시까지 남겼는데, 정작 weight가 남지 않았다 (아래 참조). 재현은 전체 재학습을 전제로 한다.

체크포인트 소실. 대회 종료 다음 날인 2026-08-21, 공용 GPU 서버 디스크 사용률 81% 상황에서 수행한 정리 작업으로 이 팀의 **학습 체크포인트·로그·생성 영상·캐시가 영구 삭제**됐다. 소스·설정·제출 CSV·provenance는 보존됐다.

학습 체인



추론



그림 10. team8 — 학습 체인이 가장 길지만, 최종 구성에서는 마지막 어댑터가 꺼져 있다.

백본	Cosmos-Predict2.5-2B action-cond (rev·SHA-256 명기) · 코드 Apache-2.0 / weight NVIDIA OML
LoRA	rank 16 / alpha 16 · q,k,v,output_proj,mlp.layer1,mlp.layer2 · AdamW 5e-5 · resolution 256
핵심 기법	warped noise (광류 기반 노이즈 사전 왜곡) + 액션 cross-attention 어댑터
추론	20-step FlowUniPC · static_anchor_v1 · 1,382.08초 / 216 샘플 (A6000 1장)
문서화	39라운드 제출 이력 · 라운드별 provenance · MANIFEST 해시 · 외부 asset 출처 대장

액션이 영상을 정말로 바꾸게 하려면, 틀린 액션과 구별하도록 가르쳐야 한다.

무엇을	유일하게 SVD 계열 월드모델(Ctrl-World)을 가져왔다. Stage A에서 attention LoRA r=128, 18채널 액션 헤드, depthwise-conv 시간 혼합기, zero-init alpha gate 를 한꺼번에 주입해 16k step 학습. alpha gate 덕에 주입 직후엔 원본 동작이 유지되고 새 경로가 서서히 열린다.
왜 통했나	Stage B·C가 차별점이다. self-attention LoRA를 얼린 채 cross-attention과 액션 경로 269텐서(30.7M)만 액션 대조 힌지 로 미세조정한다 — 맞는 액션일 때의 손실이 틀린 액션보다 마진 이상 낮아지도록 강제해, 조건 무시(condition collapse) 를 정면으로 겨냥한다.
남은 문제	부모 체크포인트를 리더보드 점수로 골랐다는 주석, 과거 학습 루프의 킷 채점 되먹임 자백, 216개 추론이 난수 흐름을 공유해 샘플 독립성이 깨지는 구조 — 검사보고서가 세 건을 중대 사안으로 올렸다.

학습 — 3 stage



추론



그림 11. team2 — 조건 무시 문제를 대조 학습으로 공략한 유일한 팀. 전처리·학습·추론이 4,486줄 단일 파일에 서버 커맨드로 들어 있다.

백본	Ctrl-World (HF yjguo/Ctrl-World) + SVD img2vid + CLIP ViT-B/32
주입 모듈	attention LoRA r128 · 18채널 액션 헤드 · depthwise-conv 시간 혼합기 · zero-init alpha gate
학습	A 16,000 → B 2,000(대조) → C 200(대조) step · 유효 배치 16을 <code>16/WORLD_SIZE</code> 로 유도해 단일 GPU 동작
데이터 분할	3계층 group-safe — fit 2,086 / sealed 300 / strict_dev 303 · margin 게이트 검증 명령 포함
재현 품질	모든 argparse 기본값 = 제출 런 값 · 경로는 <code>__file__</code> 기준 상대경로 · 동봉물 sha256 명기



team6

제출물 없음

grad/team6/ 디렉터리가 비어 있어 분석 대상이 없다.

서로 다른 백본에서 출발해 같은 곳에 도착했다

백본도 조건 주입도 제각각이지만, 추론 마지막 단계에서는 거의 모두 같은 처방을 썼다 — 움직이지 않아야 할 픽셀을 첫 프레임으로 되돌리는 것.

이유는 그림 1의 채점식에 있다. DINO·Video 성분(합계 0.6)은 프레임 특징의 코사인 거리인데, 생성 모델은 배경·조명·질감을 미세하게 흔드는 경향이 있고 그 드리프트가 거리로 곧장 잡힌다. 팔만 정확히 움직이고 나머지는 첫 프레임 그대로인 영상이 지표상 가장 안전하다.



그림 12. 정적 영역 복원 처방의 강도 스펙트럼. 왼쪽으로 갈수록 생성물을 살리고, 오른쪽으로 갈수록 입력 이미지로 되돌린다.

기록 상태 — 아이디어와 별개의 문제

설계의 질과 무관하게, 여덟 팀 중 다섯 팀이 재현에 필요한 무언가를 잃었거나 내지 않았다. 설계를 읽어 낼 수는 있어도 그 설계가 그 점수를 냈다는 것까지 확인하려면 각 팀에 추가 자료를 요청해야 한다.

- **team8** — 학습 체크포인트·로그·영상·캐시 전량 삭제 (서버 정리)
- **team10** — 학습 로그 유실, 모션 손실 v2 코드는 사양 기반 재작성본
- **team7** — 체크포인트 선택에 쓴 자체 채점기 `local_scorer.py` 미제출
- **team4** — 제출 영상 생성 스크립트 미포함, IDM·soup 단계 로그 미보존
- **team3** — 예측기 조상 체크포인트의 게보 불명

이 문서의 범위. 제출 README·config·소스코드와 기존 검사보고서를 읽어 설계 아이디어만 정리했다. 규정 위반 여부의 판단이 아니며, 본문에 “쟁점”으로 표시한 항목은 기존 검사보고서의 지적을 맥락으로 옮겨 적은 것이다. 코드는 읽기만 했고 실행하지 않았으며, 제출물은 수정하지 않았다.